


實驗報告

一、知識蒸餾

a. 資料集：BloodMNIST (<https://medmnist.com/>)

使用 medmnist 套件，採官方 train / val / test 切分：

11,959 / 1,712 / 3,421 張 28x28 RGB 影像、8 類。



b. 模型架構

- Teacher：ResNet-lite (3 層小型 ResNet)

參數量：174,080

- Student：輕量 CNN (3 層卷積 + 2 層全連接的輕量網路)

參數量：26,152

c. 實驗

i. 超參數選擇

以少 epoch 數快速比較，選出 validation accuracy 較優的 lr、weight_decay、KD 的 T / α 組合。

ii. 訓練模型

- Teacher Model
- Student Model (baseline)
- Student KD Model

soft-target 蒸餾

iii. 訓練結果

	Teacher	Student baseline	Student KD
Valid Acc	0.9632	0.9346	0.9562

iv. 測試結果


	Teacher	Student baseline	Student KD
Test Acc	0.9529	0.9266	0.9506
Test AUC	0.9972	0.9953	0.9970
Latency (ms/sample)	0.0339	0.0142	0.0133

- 參數壓縮比 (Teacher / Student) : 6.66x
- 模型大小壓縮比 (Teacher / Student) : 6.29x
- 推論加速比 (Teacher / Student KD) : 2.55x
- 效能保留率 (Student KD / Teacher) : 99.76%
- 準確率提升 (Student KD - Student) : +2.40%

=> KD 為 Student 模型帶來了正向幫助。

(不過本身 Teacher 和 Student 的表現差異不大，不能完全排除巧合。)

v. 混淆矩陣



明顯差異：原本 Student 在 ID 4 類別 (lymphocyte) 較容易預測成 basophil、erythroblast、immature granulocytes，透過 KD 學習後，提升此類別的正確率。

二、 半監督式學習

a. 資料集：BloodMNIST

Train dataset 隨機保留 10%/20% 的真實標籤。

b. 模型架構

不變。

c. 實驗

- 先用 10%/20% 的真實標籤做 warm-up 訓練 Teacher Model。
- confidence-threshold Pseudo-Labeling 自我訓練：
反覆把高信心的 unlabeled 樣本加入進 Train dataset，並產生 pseudo label。

vi. 訓練模型

- 僅監督式（只用 10%/20% 的真實標籤訓練）
 - Student Model (baseline)
 - Teacher Model
 - Student KD Model
- 半監督式（真實標籤訓練 + 自我訓練）
 - Teacher Model
 - Student KD Model

iii. 測試結果

	僅監督式			半監督式	
	Student baseline	Teacher	Student KD	Teacher	Student KD
10% 真實標籤					
Test Acc	0.8802	0.8609	0.8752	0.9085	0.9062
Test AUC	0.9854	0.9830	0.9833	0.9898	0.9903
20% 真實標籤					
Test Acc	0.9000	0.9258	0.9009	0.9275	0.9073
Test AUC	0.9907	0.9936	0.9908	0.9937	0.9922

10% 真實標籤：

- KD 準確率提升 (Student KD - Student) : -0.5%
- 自我訓練準確率提升 (半監督式 - 僅監督式) : +3.1%
- 與 100% 標籤 Student KD 差距 (半監督式 - 100%) : -4.4%

20% 真實標籤：

- KD 準確率提升 (Student KD - Student) : -0.09%
- 自我訓練準確率提升 (半監督式 - 僅監督式) : +0.64%
- 與 100% 標籤 Student KD 差距 (半監督式 - 100%) : -4.3%

三、 總結

1. KD 為 Student 模型帶來了正向幫助。
(不過本身 Teacher 和 Student 的表現差異不大，提升幅度也不大。)
2. 超參數候選組合有限，實驗結果並不代表最優結果。
3. 有嘗試以醫學 VLM (BiomedCLIP) 作為 Teacher Model，但由於設計規畫不完善，包括：模型選擇、資料選擇、prompt 設計等，表現沒有優於 ResNet。
4. 可能的延伸方向：
 - 加入 feature-level (中間層特徵) 蒸餾，而不只是 logits 層級的 soft-target 蒸餾。
 - 嘗試 self-distillation 或多個 Teacher 的 ensemble 蒸餾。

AI 協作說明

一、 AI 工具

● Claude


- 協助規劃流程
給目標、自己設想的規劃，請 AI 完善。
中途有別的想法想加入，請 AI 完善。
- 協助尋找模型
除了自己搜尋這份資料集常使用哪個模型外，也讓 AI 推薦。
- 協助撰寫程式碼
部分程式碼由 AI 生成，提升效率。

● Google Colab – Gemini

- 簡單修改程式碼

二、 舉例

AI 建議使用 soft-target 蒸餾，我會問他為什麼這樣設計、有哪些優缺點，並查詢相關資料，確認是否符合需求以及使用情況與 AI 描述是否一致。



三、 否決舉例

本次實驗沒有